7주차 R 프로그래밍

2019. 2. 27 Geon







- 1. 웹 크롤러 실습2
- 2. 데이터 저장 및 분석



rvest

실습1. 네이버 뉴스 목록 크롤링



'기어S3 LTE' 스마트폰 없이 단독 결제

전국 오프라인 매장에서 사용 가능한 스마트워치 단독 결제 서비스가 국내 처음 개시 ... 전자신문 | ① 1시간전



"PC와 출입증이 사라졌다"..SK텔레콤, '5G스마트오피스' 첫 적용

[이데일리 김현아 기자] SK텔레콤의 MKT Data사업팀 등 300여 명이 일하... 이데일리 | ① 1시간전



방통위, 통신장애 배상·음란물 유통 '규제강화'



삼성전자, 전 세계에 '갤럭시 언팩' 한글 광고한 이유는?

- 화제성 극대화...글로벌 주요 랜드마크서 진행 [디지털데일리 윤상호기자] 삼성전자 ... 디지털데일리 | ① 1시간전 ① 1시간전



모발 생성 세포 증식 탈모 세포치료제 길터...2020년 임상시험

모발 생성에 관여하는 세포를 이용한 세포치료제 개발에 청신호가 켜졌다. 국내 연구 ... 조선비즈 L (0) 1시간전

(i) AiRS 추천으로 구성된 뉴스를 제공합니다.

1 2 3 4 5 6 7 8 9 10 다음>

```
v
▼<div id="main_content" class="content">
  ▼<div class="list_body section_index">
    \div class="cluster">...</div>
    \div class="_persist">...</div>
    \div class="cluster">...</div>
    \div class="cluster">...</div>
    \div class="section_issue_list">...</div>
    ><div class="section_ad">...</div>
     <a id="mainNewsComponentId"></a>
     <h4 class="blind">뉴스 더보기</h4>
   ▼<div class="section_body" id="section_body">
      ▼
        ▼
         ∀<d1>
           \dt class="photo">...</dt>
           ∀<dt>
              <a href="/main/read.nhn?mode=LSD&mid=shm&sid1=1</pre>
              "nclicks(itn.airscont,'880000EA_0000000000000000
              'BDrMmEUa7btfx5Zd')">화웨이, 올해 폴더블폰 20만대
            </dt>
           ▶ <dd class data-comment="{gno:'news030,0002784097'</pre>
           'sectionHomeList'}">...</dd>
           </dl>
```



rvest

실습1. 네이버 뉴스 목록 크롤링

- 1. library(rvest)
- 2. library(dplyr)
- 3. ## 뉴스 목록 크롤링
- 4. newsURL <- "https://news.naver.com/main/main.nhn?mode=LSD&mid=shm&sid1=105"
- newsHtml <- read_html(newsURL)
- 6. newsPgList <- newsHtml %>%
- 7. html_nodes("#main_content") %>%
- 8. html_nodes("#section_body") %>%
- 9. html_node("ul")

```
> newsPgList
{xml_nodeset (1)}
[1] <NA>
```

텍스트 데이터 없음



RSelenium

실습2. Selenium 설치

selenium-server-standalone-3.141.59.jar 다운로드

https://www.seleniumhq.org/





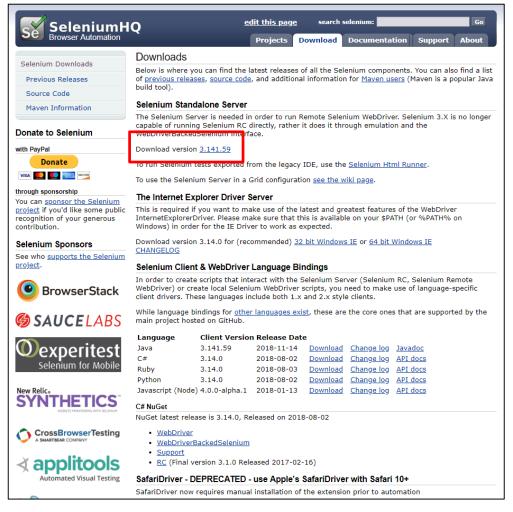
1. 웹 크롤링 실습2

RSelenium

실습2. Selenium 설치

https://www.seleniumhq.org/

selenium-server-standalone-3.141.59.jar 다운로드



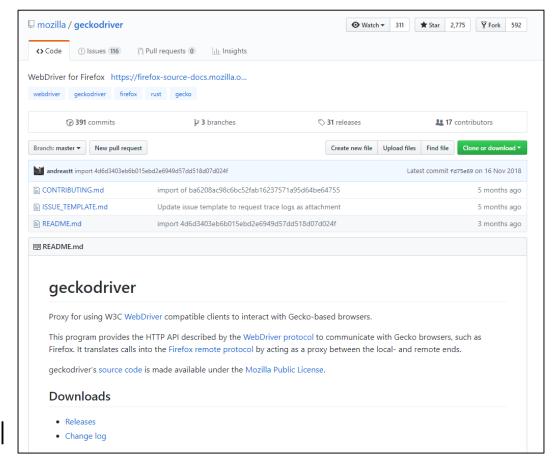


RSelenium

실습2. Selenium 설치

geckodriver.exe 다운로드

https://github.com/mozilla/geckodriver



스크롤 내리기

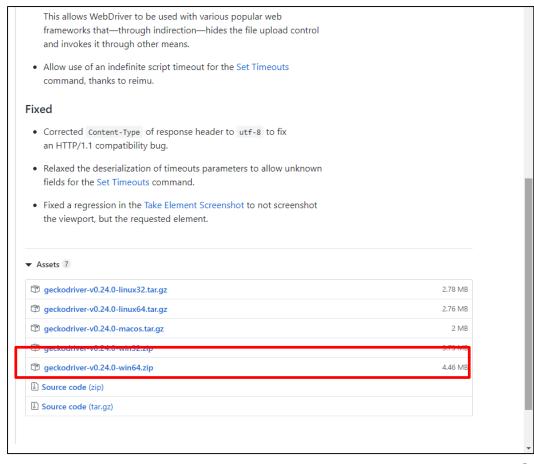


RSelenium

실습2. Selenium 설치

geckodriver.exe 다운로드

https://github.com/mozilla/geckodriver



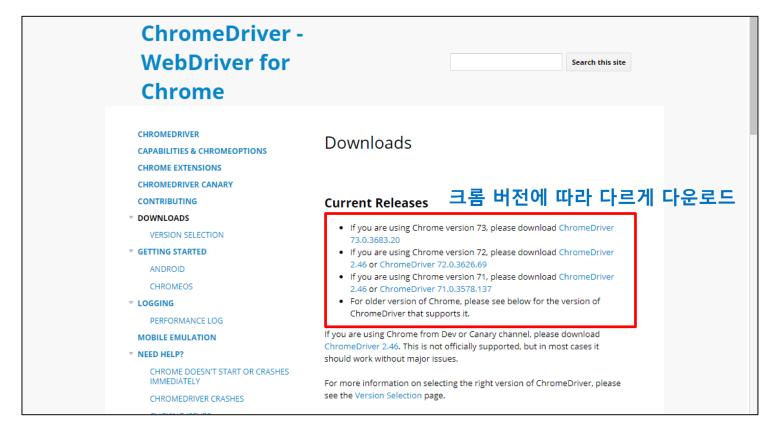


RSelenium

실습2. Selenium 설치

chromedriver.exe 다운로드

http://chromedriver.chromium.org/downloads





RSelenium

실습2. Selenium 설치

chromedriver.exe 다운로드

http://chromedriver.chromium.org/downloads

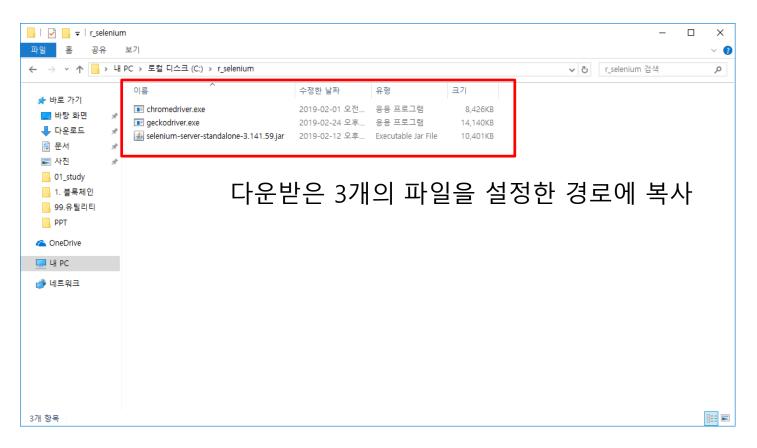
Index of /2.46/						
	<u>Name</u>	Last modified	Size	ETag		
-	Parent Directory		-			
101 01 10	chromedriver linux64.zip	2019-02-01 19:22:24	5.15MB	f 63b50301 dbce2335cdd442642d7e fa0		
101 01 10	<u>chromedriver mac64.zip</u>	2019-02-01 21:35:33	6.73MB	e287cfb628fbd9f6092ddd0353cbddaf		
10 01 10	chromedriver win32.zip	2019-02-01 21:20:53	4.42MB	d 498f 25b7a1 4216b235f1 22a615df 07a		
01 01	notes.txt	2019-02-01 21:41:08	0.02MB	3cee5a7e5102a1fe996a7bb84c52983f		



RSelenium

실습2. Selenium 설정

C:₩r_selenium (파일 경로는 자유롭게 진행 가능)

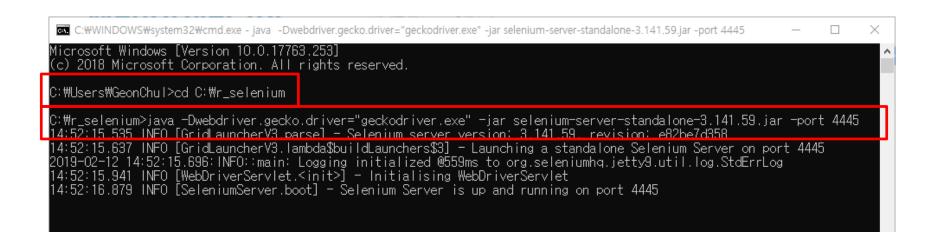




RSelenium

실습2. geckodriver 실행

- ① cmd 실행
- ② cd C:₩r_selenium
- ③ java -Dwebdriver.gecko.driver="geckodriver.exe" -jar selenium-server-standalone-3.141.59.jar -port 4445





1. 웹 크<u>롤</u>링 실습2

RSelenium

실습3. RSelenim을 활용한 크롤링 만들기

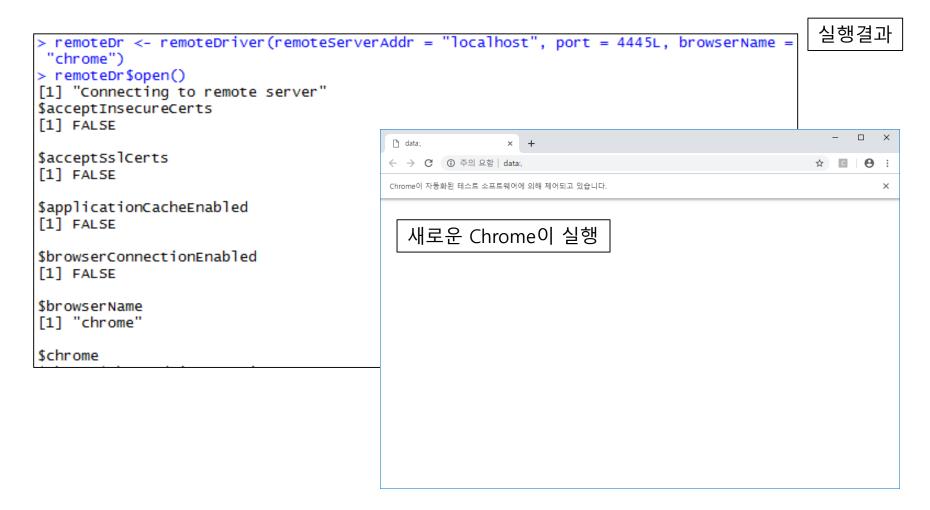
- library(RSelenium)
- ② library(rvest)
- ③ remoteDr <- remoteDriver(remoteServerAddr = "localhost", port = 4445L, browserName = "chrome")
- ④ remoteDr\$open()





RSelenium

실습3. RSelenim을 활용한 크롤링 만들기

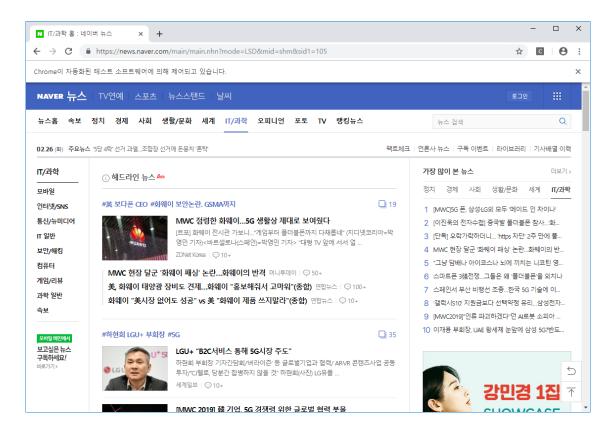




RSelenium

실습3. RSelenim을 활용한 크롤링 만들기

⑤ remoteDr\$navigate("https://news.naver.com/main/main.nhn?mode=LSD&mid=shm&sid1=105")



자동으로 URL 이동되는 것을 확인 가능



RSelenium

실습3. RSelenim을 활용한 크롤링 만들기

- 6 htmlFull <- remoteDr\$getPageSource()[[1]]</pre>
- ⑦ html <- read_html(htmlFull)</pre>
- newsList <- html %>% html_nodes("#section_body ul")

Name	Type	Value
newsList	list [4] (S3: xml_nodeset)	List of length 4
○ [[1]]	list [2] (S3: xml_node)	List of length 2
	list [2] (S3: xml_node)	List of length 2
	list [2] (S3: xml_node)	List of length 2
	list [2] (S3: xml_node)	List of length 2
	list [2] (S3: xml_node)	List of length 2
	list [2] (S3: xml_node)	List of length 2
(xml attributes)	character [1]	'type06_headline'
[[2]]	list [2] (S3: xml_node)	List of length 2
[[3]]	list [2] (S3: xml_node)	List of length 2
[[4]]	list [2] (S3: xml_node)	List of length 2

텍스트 데이터 존재



RSelenium

실습3. RSelenim을 활용한 크롤링 만들기

- 9 for(one in newsList) {
- ① print(temp)
- 12

```
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=092&aid=0002157054"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=092&aid=0002157054"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=448&aid=0000267714"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=448&aid=0000267714"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=018&aid=0004318933"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=018&aid=0004318933"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=018&aid=0004318903"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=018&aid=0004318903"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=008&aid=0004180234"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=008&aid=0004180234"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=020&aid=0003201030"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=020&aid=0003201030"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=366&aid=0000427833"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=366&aid=0000427833"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=028&aid=0002444474"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=028&aid=0002444474"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=015&aid=0004099319"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=015&aid=0004099319"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=029&aid=0002510954"
"/main/read.nhn?mode=LSD&mid=shm&sid1=105&oid=029&aid=0002510954"
```

Q&A